Sistema de Detección de Intrusos (IDS)

con Redes Neuronales

Dataset

NSL-KDD

Modelos

MLP + Transfer Learning

Materia

Redes Neuronales

César Núñez

2026

1. Problema y Motivación

PROBLEMA

Clasificar tráfico de red para detectar intrusiones y ataques cibernéticos.

DATASET — NSL-KDD

Registros de conexiones TCP/IP etiquetadas por tipo de tráfico — Normal, DoS, Probe, R2L y U2R — con atributos como duración, bytes transferidos, protocolo, flags, intentos de login fallidos, comandos ejecutados y estadísticas de conexión.

Tipos de Problema

01

Clasificación Binaria

¿Es la conexión Normal o un Ataque?

02

Clasificación Multiclase

Transfer Learning sobre modelo base.

- Normal.
- DoS.
- Probe.

2. Datos y Preprocesamiento

125.973	22.544	41	80 / 20
Registros train	Registros test	Variables (features)	Train / Val split

1. Label Encoding

protocol_type, service, flag → valores enteros

2. Exclusión R2L & U2R

< 1% del dataset (1.047 registros)

3. StandardScaler

Normalización (ej. src_bytes: 0 – 1.3M)

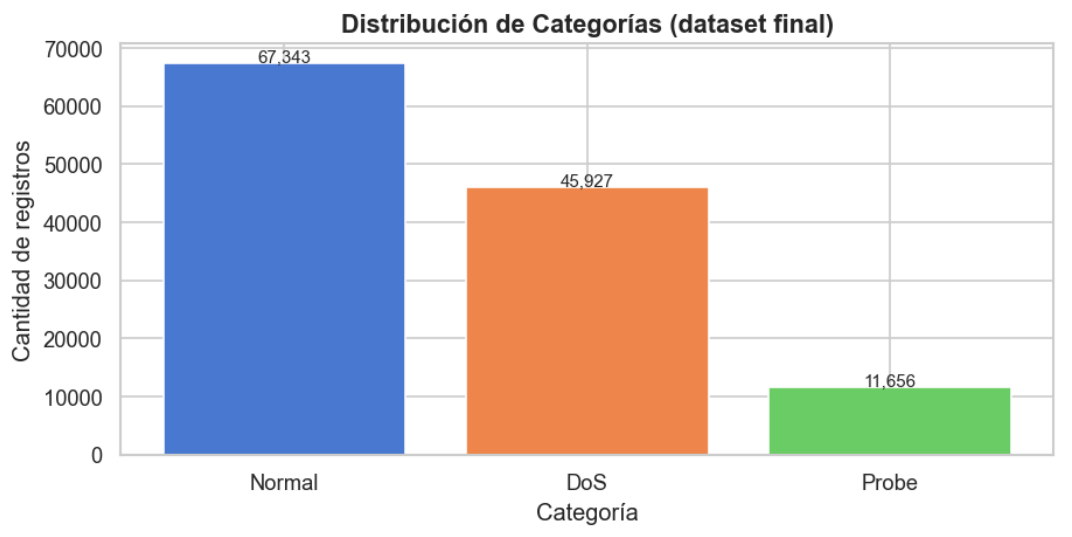

3. Modelos Utilizados

MODELO BASE — MLP Binario

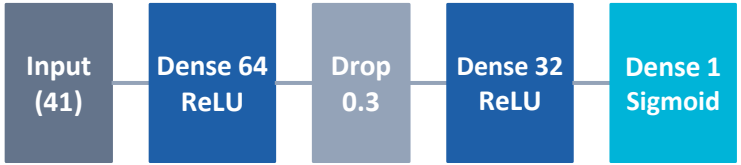

Parámetros: 4.801 · Loss: Binary Crossentropy · Optimizer: Adam

ReLU Evita gradiente desapareciente, acelera convergencia

Dropout 0.3 Regularización → previene overfitting

Sigmoid Salida de probabilidad [0,1] para clasificación binaria

EarlyStopping Restaura mejores pesos (patience=5)

Umbral de decisión 0,20 (maximiza recall de ataques)

TRANSFER LEARNING — 3 Clases

Extractor (congelado) → Nueva cabeza (entrenable)

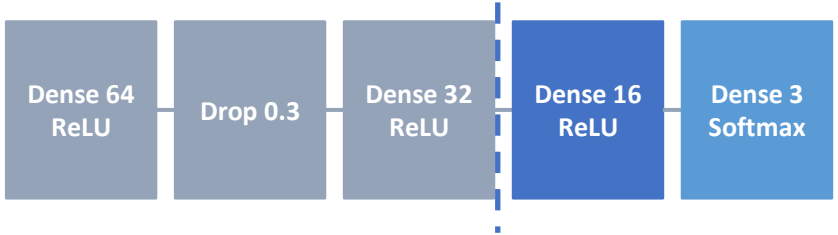

Parámetros entrenables: 5,347 · Loss: Sparse Categorical CE

Capas congeladas Reutilizan representaciones del tráfico de red

Nueva cabeza Aprende a distinguir Normal / DoS / Probe

Softmax Distribución de probabilidad sobre 3 clases

Excl. R2L & U2R Desequilibrio severo → F1 = 0.00 si se incluyen

Métrica: Accuracy + F1-Score (macro) + Precisión

4. Resultados – Curvas de Aprendizaje

MODELO BASE — MLP Binario

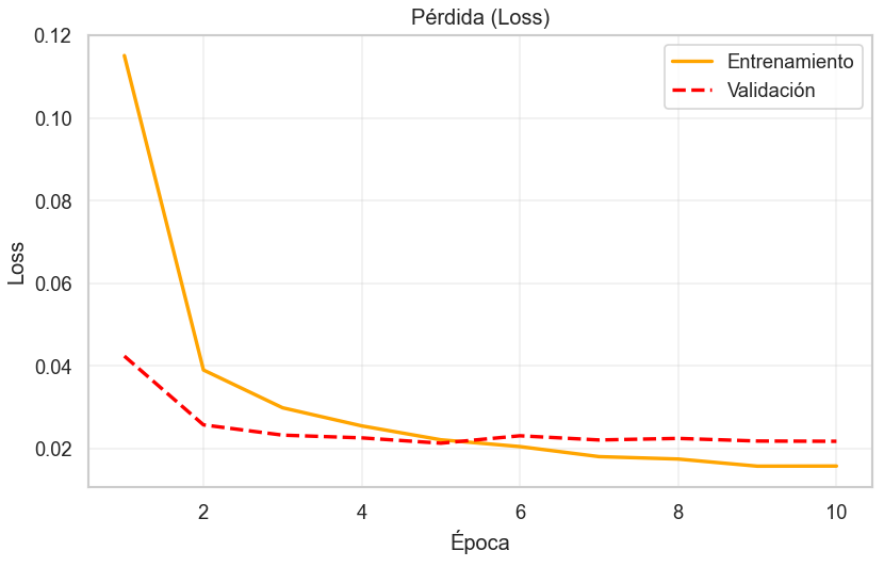

TRANSFER LEARNING — 3 Clases

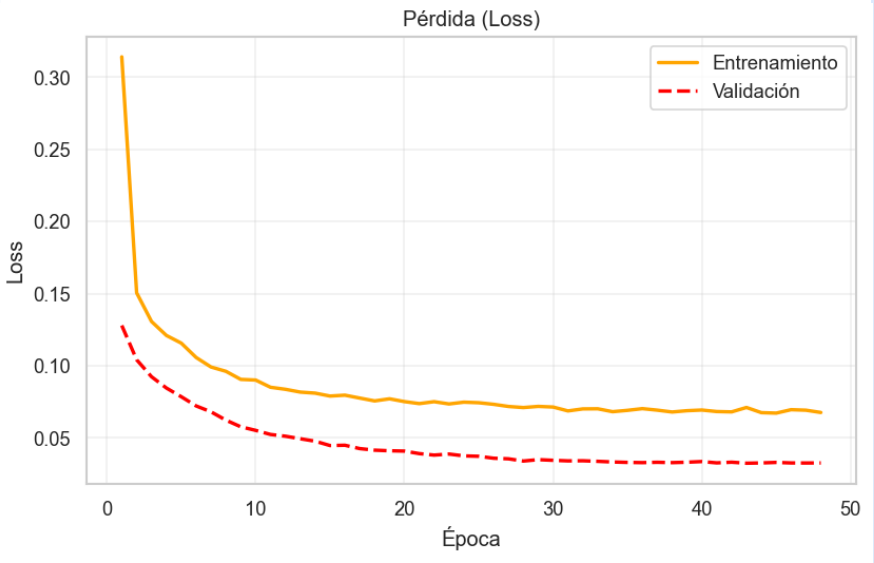

4. Resultados – Clasificación Multiclase

Matriz de Confusión

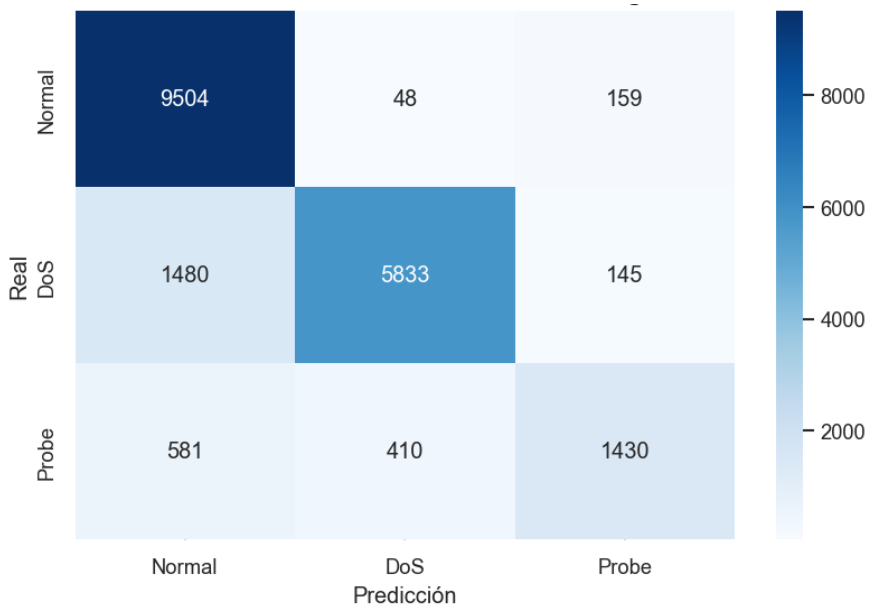

Comparativa de Modelos

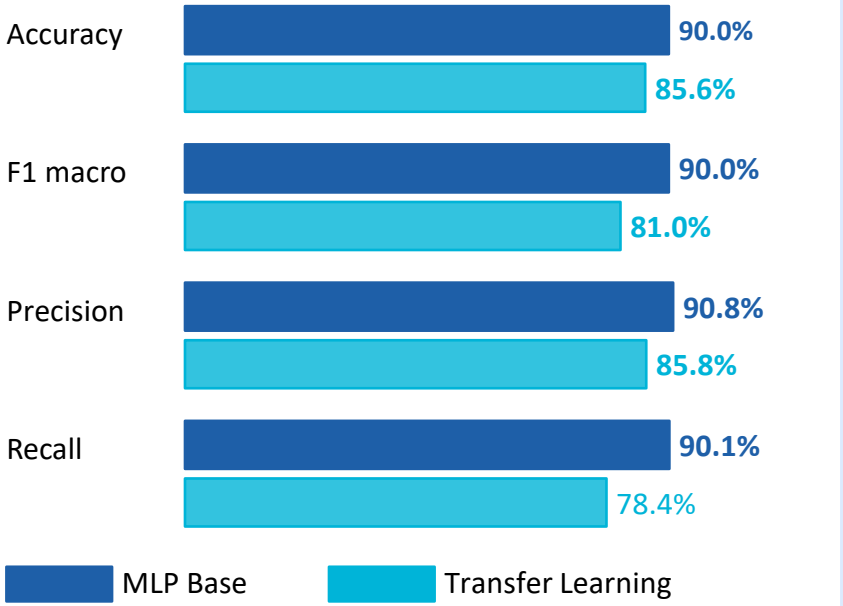

5. Conclusiones y Aprendizajes

Aprendizajes clave:

- Dropout controló el overfitting efectivamente.
- El umbral de decisión (0.20) fue tan clave como la arquitectura.
- Desplegado en una app para detección de intrusos a través de datos CSV.

Limitaciones:

- NSL-KDD de 1999, no refleja ataques modernos.
- R2L y U2R excluidas por desequilibrio severo (< 1%).

Mejoras:

- LSTM para secuencias temporales.
- Autoencoder para anomalías desconocidas.

Visualización en Hugging Face

IDS con Redes Neuronales (NSL-KDD)

Subir test_heterogeneo.csv

test_heterogeneo.csv 14.9 KB

🚀 Analizar en Batch

Resumen del Análisis

📊 Análisis Completado

Total registros: 118
✅ Tráfico Normal: 78
🔴 Ataques: 40

Resultados Detallados

#	Clasif. Binaria	Confianza	Categoría	Confianza
1	🔴 Ataque	100.00%	DoS	99.17%
2	✅ Normal	99.98%	Normal	100.00%
3	🔴 Ataque	100.00%	Probe	96.29%
4	✅ Normal	98.90%	Normal	99.75%
5	✅ Normal	99.94%	Normal	99.99%
6	🔴 Ataque	100.00%	DoS	89.75%
7	🔴 Ataque	99.89%	DoS	95.80%
8	🔴 Ataque	100.00%	Probe	95.78%
9	✅ Normal	97.41%	Normal	98.21%
10	🔴 Ataque	92.08%	DoS	85.84%
11	✅ Normal	99.88%	Normal	100.00%
12	✅ Normal	100.00%	Normal	100.00%

¡Gracias por su atención!